01 Học ML từ con số 0

Tài liệu cho người chưa biết Machine Learning. Bạn chưa cần biết Python, thống kê hay các công thức đại học để bắt đầu.

Mục tiêu của tài liệu

Bạn sẽ hiểu máy học từ ví dụ như thế nào, dữ liệu và đáp án khác nhau ở đâu, cách kiểm tra một mô hình, rồi mới liên hệ với đồ án EEG N16. Mỗi từ mới được giải thích trước khi sử dụng nhiều lần.

Phần đầu dùng một ví dụ phân biệt táo và cam bằng dữ liệu giả định. Đây là cách học tư duy ML, không phải phương pháp nhận dạng trái cây đáng tin cậy trong đời thật.

Học khi rảnh	Đọc phần nào	Sau đó tự giải thích được
Buổi 1	Trang 2–4	ML, dữ liệu, đặc trưng và nhãn
Buổi 2	Trang 5–8	Máy học và dự đoán như thế nào
Buổi 3	Trang 9–11	Kiểm tra đúng và đọc kết quả
Buổi 4	Trang 12–14	Python tối thiểu và liên hệ EEG
Buổi 5	Trang 15–18	Bài tập, đáp án và ôn lại

Cách học để không bị ngợp

Đọc một trang rồi kể lại bằng lời của mình. Nếu còn nhầm, đọc lại ví dụ trước khi sang trang tiếp. Chưa cần ghi nhớ tên mọi thuật toán. Hãy ưu tiên hiểu: máy nhận gì, học từ đáp án nào và được kiểm tra trên ví dụ nào.

Mọi con số của ví dụ trái cây hoặc bài tập là minh họa. Chúng không phải kết quả thực nghiệm của đồ án. Tài liệu được soạn ngày 03/11/2026, dùng bối cảnh dự án để giải thích ở phần cuối.

02 ML là gì

ML là viết tắt của Machine Learning, tiếng Việt là học máy. Ta đưa cho chương trình các ví dụ để nó xây dựng một cách dự đoán, thay vì tự viết hết mọi quy tắc cho mọi trường hợp.

So sánh với một chương trình có quy tắc cố định

Giả sử ta tự viết: “Quả nặng dưới 140 gam thì đoán là táo”. Đây là một quy tắc do người viết chọn. Chương trình chỉ làm đúng câu lệnh, không có bước học từ ví dụ.

Trong một bài ML, ta có thể đưa nhiều quả đã biết tên cùng số đo của chúng. Một thuật toán sử dụng các ví dụ để xây dựng mô hình. Mô hình là cách biểu diễn quy luật hoặc thông tin đã học, dùng để trả lời cho quả mới.

Từ mới	Hiểu ngắn gọn
Thuật toán	Các bước mà chương trình thực hiện
Mô hình	Cách dự đoán được hình thành từ quá trình học
Huấn luyện	Cho thuật toán sử dụng ví dụ để tạo hoặc điều chỉnh mô hình
Dự đoán	Dùng mô hình để trả lời cho một đầu vào

Máy không tự hiểu như con người

Máy nhận các giá trị mà ta cung cấp, như cân nặng hoặc màu đã mã hóa. Nó không tự hiểu cảm giác nhìn một quả cam. Nếu ví dụ sai, số đo sai hoặc đáp án sai, mô hình có thể học một cách dự đoán sai.

ML có thể là một thành phần của trí tuệ nhân tạo, thường viết là AI. Hai từ này không hoàn toàn đồng nghĩa. Ở giai đoạn này, bạn chỉ cần nắm quy trình học từ dữ liệu.

Tự kiểm tra

Bạn tự chọn ngưỡng 140 gam rồi viết if/else: chưa có bước học ML. Bạn dùng một thuật toán để chọn cách dự đoán từ nhiều ví dụ: đã có bước học. Mô hình học xong vẫn có thể dự đoán sai.

03 Dữ liệu là những gì ta ghi lại

Dữ liệu là thông tin được thu thập và lưu lại. Với ví dụ trái cây, đó có thể là cân nặng và tên quả. Với EEG, đó là các giá trị tín hiệu và thông tin đo.

Một bảng dữ liệu giả định

Mã quả	Cân nặng gam	Tên đã biết
A	80	Táo
B	100	Táo
C	120	Táo
D	160	Cam
E	180	Cam
F	200	Cam

Một hàng biểu diễn một quả trong ví dụ này. Một cột biểu diễn một loại thông tin, chẳng hạn cân nặng. Một ô là một giá trị cụ thể tại chỗ giao giữa hàng và cột.

Bảng có 6 hàng dữ liệu và 3 cột. Hàng tiêu đề không tính là một quả. Nếu lưu dạng CSV, chương trình có thể đọc các hàng và cột này để xử lý.

Số dòng không nói hết chất lượng

Nếu sao chép quả A thành 1.000 hàng giống nhau, ta chưa có 1.000 quả được đo độc lập. Bảng dài hơn nhưng không có thêm loại tình huống. Tương tự, nhiều dòng EEG không tự có nghĩa nhiều người tham gia.

Nếu cân của bạn đo sai, nhãn bị gõ nhầm hoặc dữ liệu chỉ đến từ một tình huống, kết quả học có thể không dùng được ở tình huống khác. Vì vậy, kiểm tra dữ liệu là công việc quan trọng trước khi chọn mô hình.

Tự kiểm tra

Trong bảng này, con số 120 là cân nặng của quả C. Chữ “Táo” là đáp án đã biết. Chỉ nhìn mã C thì không nên cho rằng máy đã biết tên quả.

04 Đặc trưng và nhãn khác nhau thế nào

Đặc trưng, tiếng Anh là feature, là thông tin ta cho mô hình dùng để dự đoán. Nhãn, tiếng Anh là label, là đáp án tham khảo của một ví dụ trong bài học có đáp án.

Thành phần	Trong bảng trái cây	Vai trò
Đặc trưng X	Cân nặng	Thông tin mô hình được nhìn
Nhãn y	Táo hoặc cam	Đáp án dùng để học và chấm
Mã quả	A, B, C…	Giúp tra lại bản ghi, không phải tên quả

Một mẫu là một ví dụ

Trong bảng trái cây, quả C có đặc trưng cân nặng 120 và nhãn Táo. Ta gọi đó là một mẫu. “Mẫu” không có một ý nghĩa giống nhau trong mọi file: bạn phải biết một hàng của bảng đang đại diện cho gì.

Sau này, một mẫu ML của đồ án có thể là các đặc trưng tính từ 4 giây EEG. Mỗi dòng raw trong CSV lại chỉ là một giá trị tín hiệu ở một thời điểm. Hai cấp này không giống nhau.

Đừng đưa đáp án vào đầu vào

Nếu bạn đưa cả cột tên quả cho máy rồi yêu cầu đoán tên quả, máy đã nhìn đáp án. Điểm kiểm tra cao khi đó không chứng minh máy có khả năng nhận dạng quả chưa biết.

Trong ví dụ đầu tiên, X chỉ gồm cân nặng. Nếu thêm màu sắc và kích thước, X có nhiều cột. Thêm đặc trưng có thể hữu ích, nhưng không phải càng nhiều càng tốt: cột sai hoặc không liên quan cũng có thể gây khó.

Tự kiểm tra

Bạn muốn đoán giá căn phòng. Diện tích có thể là đặc trưng, giá là đáp án. Bạn muốn đoán tỉnh/buồn ngủ: đặc trưng EEG là đầu vào; nhãn trạng thái đã xác minh là đáp án, không được lén đưa vào X.

05 Có những kiểu bài học nào

Phần chính của tài liệu tập trung vào học có giám sát: các ví dụ dùng để học đã có đáp án. Học có giám sát có hai dạng rất thường gặp là phân loại và hồi quy.

Kiểu bài	Câu hỏi	Đầu ra
Phân loại	Quả này là táo hay cam?	Một lớp, như Táo
Phân loại	Cửa sổ EEG này tỉnh hay buồn ngủ?	Một trong hai lớp
Hồi quy	Giá căn phòng này khoảng bao nhiêu?	Một số dự đoán
Hồi quy	Mức PERCLOS liên tục khoảng bao nhiêu?	Một số từ mô hình, cần kiểm tra miền hợp lệ

Học không giám sát

Nếu chỉ có số đo mà không có đáp án, một thuật toán có thể tìm các nhóm ví dụ giống nhau. Đó là một hướng học không giám sát, chẳng hạn phân cụm.

Nhưng tìm được hai cụm không có nghĩa cụm thứ nhất chắc chắn là tỉnh và cụm thứ hai là buồn ngủ. Hai nhóm có thể khác nhau vì người đo, thiết bị hoặc nhiễu. Ta vẫn cần bằng chứng để hiểu các cụm.

Đồ án N16 đang đi theo hướng nào

Bài phân biệt tỉnh/buồn ngủ là phân loại có giám sát. Ta cần chuẩn bị các ví dụ và nhãn đáng tin cậy. Nếu dùng điểm PERCLOS liên tục của SEED-VIG để dự đoán trực tiếp, đó có thể trở thành một bài hồi quy riêng.

Đừng nhầm tên lớp với số thứ tự

Có thể quy ước tỉnh = 0, buồn ngủ = 1. Các số đó là cách mã hóa hai tên lớp; không có nghĩa buồn ngủ “gấp một lần” tỉnh. Với ba loại quả, mã 0, 1, 2 cũng không biểu diễn mức độ hơn kém giữa các quả.

06 Quy trình học và dự đoán

Bước	Bạn thực hiện gì	Ví dụ trái cây
1	Thu thập ví dụ	Cân nhiều quả và ghi đúng tên
2	Kiểm tra dữ liệu	Tìm ô trống, cân sai, tên gõ nhầm
3	Chọn đầu vào và đáp án	X là cân nặng; y là tên
4	Tách phần học và phần kiểm tra	Giữ lại một số quả chưa dùng để học
5	Huấn luyện mô hình	Cho thuật toán sử dụng phần học
6	Dự đoán rồi chấm	So tên đoán với tên thật của phần giữ lại

Huấn luyện không phải là đoán mọi thứ

Huấn luyện là giai đoạn mô hình sử dụng các ví dụ được phép học. Sau đó ta đưa một đầu vào để dự đoán. Trong lúc dự đoán, mô hình không cần nhận nhãn thật của quả mới.

Tên hàm thường gặp trong Python là fit để học, predict để dự đoán. Bạn chưa cần biết cú pháp; chỉ cần hiểu hai việc này khác nhau.

Ví dụ mới có thể làm máy sai

Giả sử bảng học có táo nhỏ và cam lớn. Mô hình có thể dựa rất nhiều vào cân nặng. Khi gặp táo rất lớn hoặc cam rất nhỏ, nó có thể đoán sai vì những tình huống đó chưa được thể hiện tốt trong dữ liệu học.

Đó là lý do không thể kết luận chỉ bằng việc chương trình chạy không báo lỗi. Một chương trình hoạt động về kỹ thuật vẫn có thể tạo mô hình dự đoán kém.

Câu cần nhớ

Dữ liệu tốt giúp việc học có ý nghĩa. Tách kiểm tra đúng giúp ta biết mô hình làm được đến đâu. Mô hình phức tạp không tự sửa được đáp án sai.

07 Tính tay một dự đoán đơn giản

Ta thử một cách gọi là láng giềng gần nhất. Ý tưởng: tìm ví dụ đã biết giống đầu vào mới nhất, rồi dùng nhãn của ví dụ đó làm dự đoán. Đây là một ví dụ trực quan của phương pháp k gần nhất, thường viết kNN, với k = 1.

Dự đoán một quả nặng 110 gam

Ví dụ đã biết	Cân nặng	Khoảng cách tới 110
Táo A	80	30
Táo B	100	10
Táo C	120	10
Cam D	160	50
Cam E	180	70
Cam F	200	90

Ở đây, khoảng cách là chênh lệch cân nặng không lấy dấu âm. Hai ví dụ gần nhất đều là táo, nên dù chọn một trong hai, kết quả vẫn là Táo. Máy không biết quả đó thật sự là gì; nó chỉ dựa trên thông tin trong ví dụ.

Quả nặng 170 gam thì sao

Hai số gần nhất là 160 và 180, đều mang nhãn Cam. Dự đoán là Cam. Nếu quả thật là một quả táo rất to, dự đoán vẫn sai. Muốn biết đúng hay sai phải có đáp án độc lập để chấm.

Trong phương pháp này máy học gì

Không phải mọi thuật toán đều học một công thức có trọng số. Với cách láng giềng, thông tin các ví dụ và cách đo khoảng cách rất quan trọng. Khi dự đoán, thuật toán tìm các ví dụ phù hợp để tham khảo.

Bạn đã hiểu được một mô hình mà chưa cần giải phương trình. Học ML từ đầu nên đi theo cách này: hiểu đầu vào, thao tác và đầu ra trước, rồi mới học công thức chi tiết.

08 Các mô hình khác nhau ở cách dự đoán

Có nhiều thuật toán vì các bài toán có cấu trúc khác nhau. Ở bước nhập môn, bạn chưa cần thuộc công thức; hãy nắm ý tưởng cơ bản của từng tên.

Tên thường gặp	Cách hình dung ban đầu
Cây quyết định	Đặt các câu hỏi theo nhánh rồi đi đến kết luận
Random Forest	Kết hợp nhiều cây để tạo dự đoán chung
Logistic Regression	Cộng các đặc trưng với trọng số rồi tạo điểm cho bài phân loại
SVM	Tìm ranh giới phân biệt các nhóm ví dụ
kNN	Dựa vào các ví dụ ở gần đầu vào mới

Một cây nhỏ để hình dung

Trong dữ liệu giả định, thuật toán có thể học một câu hỏi: cân nặng có nhỏ hơn 140 gam không? Nếu có thì đoán Táo, nếu không thì đoán Cam. Ngưỡng được học từ train khác với ngưỡng do bạn tự viết mà không có bước học.

Nếu dữ liệu đổi, ngưỡng hoặc cả cấu trúc cây có thể đổi. Không có lý do lấy 140 gam làm quy tắc cho mọi loại trái cây ngoài đời.

Tham số là gì

Tham số là các giá trị mô hình sử dụng để đưa ra dự đoán. Ví dụ có thể là ngưỡng trong một cây hoặc các trọng số trong một mô hình tuyến tính. Còn cấu hình như chọn bao nhiêu cây thường do người làm thí nghiệm lựa chọn trước hoặc điều chỉnh trong quá trình phát triển.

Nên học tên nào trước

Với đồ án, bạn sẽ gặp Logistic Regression, SVM và Random Forest trong ứng dụng. Trước khi so sánh chúng, cần có dữ liệu, nhãn và cách kiểm tra đúng. Đổi mô hình mà giữ lỗi trong dữ liệu thường không giải quyết được vấn đề gốc.

09 Tại sao phải giữ một phần để kiểm tra

Nếu học thuộc 10 câu hỏi rồi được kiểm tra lại đúng 10 câu đó, bạn chưa chứng minh mình giải được câu mới. Một mô hình cũng có thể làm tốt trên ví dụ đã học nhưng kém trên ví dụ chưa gặp.

Tên	Tiếng Việt	Mục đích
Train	Tập học	Dùng để học các tham số
Validation	Tập xác thực	Giúp lựa chọn cấu hình trong quá trình phát triển
Test	Tập kiểm tra	Đánh giá sau khi đã khóa lựa chọn

Ví dụ cách chia

Có 100 quả khác nhau, bạn có thể dành một phần để học và một phần giữ lại kiểm tra. Tỷ lệ 80/20 là một ví dụ dễ hình dung, không phải quy định mọi bài ML đều phải dùng. Khi cần chọn nhiều cấu hình, phải tổ chức thêm phần xác thực hoặc quy trình đánh giá chéo phù hợp.

Với EEG phải chú ý người và thời gian

Nếu các cửa sổ đến từ cùng một đoạn tín hiệu, chúng có thể rất giống nhau. Chia ngẫu nhiên các hàng có thể đưa dữ liệu gần như trùng nhau vào cả học và kiểm tra, làm kết quả quá lạc quan.

Muốn biết mô hình dùng được với người mới không, phải giữ dữ liệu của người đó ngoài phần học. S01 có sáu phiên vẫn chỉ là một người. Không đổi mã một phiên thành S02 để tạo người mới giả.

LOSO là từ bạn sẽ gặp

LOSO nghĩa là lần lượt giữ một người làm test và học trên các người còn lại. Với S01 và S02: lượt một học S01, kiểm tra S02; lượt hai làm ngược lại. Nếu tập học chỉ có một lớp, nhiều classifier hai lớp không thể học được bài phân biệt cần làm.

10 Học quá thuộc và lộ đáp án

Overfitting, hay quá khớp, là khi mô hình bám quá nhiều vào chi tiết của dữ liệu học nên khó dùng cho dữ liệu mới. Điểm train rất cao không tự chứng minh mô hình tốt.

Ví dụ dễ hiểu

Giả sử ảnh táo trong bộ học đều chụp trên bàn trắng, ảnh cam đều chụp trên bàn đen. Mô hình có thể học màu bàn thay vì đặc điểm quả. Đổi bàn khi dùng thật có thể làm dự đoán sai.

Trong EEG, điều tương tự có thể xảy ra nếu phiên tỉnh luôn dùng một hoạt động, còn phiên buồn ngủ luôn dùng hoạt động khác hoặc có điều kiện nhiễu khác. Cần ghi nhiệm vụ và giữ điều kiện đủ nhất quán để đánh giá điều mình muốn đo.

Data leakage là rò rỉ dữ liệu

Đây là khi quá trình học hoặc chọn mô hình sử dụng thông tin lẽ ra chưa được biết. Ví dụ: đưa nhãn vào cột đầu vào; để hai cửa sổ chồng nhau ở hai phía học/test; tính thông số xử lý bằng cả người test trước khi đánh giá.

Chuẩn hóa là gì

Chuẩn hóa là đổi các cột số về một thang dựa trên một quy tắc. Ví dụ một cột tính bằng hàng nghìn và cột khác nhỏ hơn 1 có thể cần biến đổi trước khi học. Nếu quy tắc cần tính trung bình hoặc độ lệch từ dữ liệu, chỉ học các số đó bằng train rồi dùng lại cho test.

Bạn chưa cần tính độ lệch chuẩn ngay. Chỉ cần nhớ: “học bước xử lý từ train, không nhìn trước test”. Pipeline là tên một chuỗi bước xử lý được ghép với mô hình để thực hiện nhất quán.

Tự kiểm tra

Thấy kết quả test thấp rồi sửa mô hình đến khi test đẹp: test đã ảnh hưởng quá trình lựa chọn. Cần phân biệt phần phát triển và phần chấm cuối, không liên tục tối ưu trực tiếp vào bài kiểm tra.

11 Đọc đúng và sai của mô hình

Giả sử lớp cần phát hiện là buồn ngủ. Ta gọi đó là lớp dương, thường mã hóa là 1; tỉnh là lớp 0. Đây chỉ là quy ước tên, không phải nhận xét trạng thái nào tốt hơn.

Sự thật	Máy đoán tỉnh	Máy đoán buồn ngủ
Tỉnh	5 đúng: TN	1 báo nhầm: FP
Buồn ngủ	2 bỏ sót: FN	2 bắt đúng: TP

Tổng có 10 ví dụ. Máy đúng 5 + 2 = 7, nên accuracy, tức tỷ lệ đúng chung, là 7/10 = 70%.

Tên chỉ số	Câu hỏi cần trả lời	Trong ví dụ
Precision	Trong những lần máy báo buồn ngủ, bao nhiêu lần đúng?	2/(2+1) ≈ 66,7%
Recall	Trong những mẫu buồn ngủ thật, máy bắt được bao nhiêu?	2/(2+2) = 50%

Vì sao một con số chưa đủ

Máy có thể đạt accuracy cao bằng cách luôn đoán lớp phổ biến nhất. Ví dụ có 95 mẫu tỉnh và 5 mẫu buồn ngủ: luôn đoán tỉnh đạt 95% đúng chung nhưng bỏ sót cả 5 mẫu cần phát hiện, recall buồn ngủ bằng 0%.

F1 là chỉ số kết hợp precision và recall; bạn có thể học công thức sau. Trước hết hãy phân biệt báo nhầm và bỏ sót. Trong đồ án, 10 cửa sổ không nhất thiết là 10 sự kiện buồn ngủ độc lập.

Dự đoán có chắc chắn đúng không

Không. Một số mô hình trả điểm hoặc xác suất ước lượng, nhưng đó không phải sự thật chắc chắn. Điểm 0,8 của SVM cũng không tự là xác suất 80%. Ta vẫn cần kiểm tra bằng dữ liệu có đáp án đáng tin cậy.

12 Nếu chưa biết Python thì bắt đầu thế nào

Python là một ngôn ngữ lập trình, không phải ML. ML là cách giải bài toán; Python là một công cụ để thực hiện. Bạn có thể học tư duy ML trước rồi học đủ Python để hiểu và sử dụng mã.

Bốn khái niệm nhỏ

Khái niệm	Ví dụ	Ý nghĩa
Biến	can_nang = 110	Đặt tên cho một giá trị
Danh sách	ds = [80, 100, 120]	Lưu nhiều giá trị theo thứ tự
Hàm	len(ds)	Thực hiện một công việc; ở đây là đếm phần tử
Điều kiện	if can_nang < 140:	Chọn thao tác khi điều kiện đúng

Ví dụ len([80, 100, 120]) cho kết quả 3. Đây chỉ là đếm số phần tử, chưa phải huấn luyện một mô hình. Viết if/else cũng chưa tự động biến chương trình thành ML.

Thư viện là gì

Thư viện là tập hợp công cụ đã được viết để bạn sử dụng lại. pandas thường giúp đọc bảng; NumPy xử lý mảng số; scikit-learn cung cấp nhiều công cụ ML. Bạn không cần tự viết lại mọi phép toán để bắt đầu.

Thứ tự học lập trình tối thiểu

Học biến, kiểu số/chữ, danh sách, if, vòng lặp và hàm. Sau đó học mở CSV, chọn cột và kiểm tra dữ liệu. Khi hiểu các thao tác này, đọc fit và predict sẽ dễ hơn nhiều.

Trong đồ án hiện tại, bạn có ứng dụng giao diện để thao tác. Việc chưa thuộc Python không ngăn bạn hiểu quy trình, nhưng cần dần đọc được: cột nào là đầu vào, cột nào là nhãn và người nào được giữ lại kiểm tra.

Tự kiểm tra

Đọc được một file CSV là thao tác dữ liệu. Gọi fit trên dữ liệu có nhãn là một bước học. Gọi predict là bước dự đoán. Ba việc này khác nhau.

13 Áp dụng kiến thức vào EEG của bạn

EEG là tín hiệu điện não được thiết bị ghi lại. Trong đồ án, bạn dùng một kênh NeuroSky, tần số danh định 512 Hz. Hiểu đơn giản: mỗi giây có 512 giá trị raw, tức dữ liệu tín hiệu chưa được biến thành một hàng đặc trưng ML.

Khái niệm đã học	Trong đồ án N16
Dữ liệu đầu vào ban đầu	CSV có thời gian và cột Electrode
Một cửa sổ	Ví dụ 4 giây gồm 2.048 giá trị raw
Đặc trưng	Các số mô tả cửa sổ: công suất dải tần, tỷ số, chớp mắt ước lượng
Nhãn	Tỉnh/buồn ngủ theo quy trình KSS đã xác minh
Mô hình	Logistic Regression, SVM hoặc Random Forest
Kết quả dự đoán	Một nhãn hoặc điểm của mô hình cho cửa sổ mới

KSS là gì trong quy trình học

KSS là thang tự đánh giá mức buồn ngủ, bạn ghi điểm thực tế theo các mốc. Quy ước đang có trong mã dự án là 1–5 thuộc phía tỉnh, 7–9 thuộc phía buồn ngủ, còn 6 không dùng cho bài hai lớp. Quy tắc này cần được chốt với GVHD và không tự biến mỗi điểm thành nhãn cho toàn phiên.

Vì sao cần lọc rồi mới tính đặc trưng

Tín hiệu có thể chứa nhiễu điện lưới, chuyển động hoặc giá trị bất thường. Nếu dùng nguyên mọi đoạn, mô hình có thể học đặc điểm nhiễu. Phần xử lý tạo bản riêng, đánh dấu vùng lỗi và giữ raw gốc để kiểm tra.

Lọc không biết đáp án tỉnh/buồn ngủ. Nhãn vẫn phải dựa trên thông tin đã ghi và cách căn thời gian phù hợp. Không lấy phiên buổi tối hoặc số thứ tự file làm đáp án thay cho KSS.

14 Bạn đang ở đâu trong đồ án

Theo hồ sơ xử lý sáu phiên S01 đã tạo, có 1.291 cửa sổ ứng viên dài 4 giây sau một bộ quy tắc sàng lọc và tránh vùng biên lọc. Tổng tương đương 86 phút 4 giây. “Ứng viên” nghĩa là cần kiểm tra tiếp, chưa đồng nghĩa dữ liệu sạch có nhãn.

Phân biệt bốn trạng thái

Trạng thái	Điều đó chứng minh gì
Đọc được CSV	Phần mềm hiểu cấu trúc file
Đã lọc và sàng lọc	Đã xử lý theo một quy tắc kỹ thuật
Có nhãn đã xác minh	Có thể chuẩn bị các ví dụ học có đáp án
Đã đánh giá đúng	Có kết quả giới hạn theo thiết kế kiểm tra thực tế

Không bỏ qua hai bước cuối chỉ vì đã có bản lọc. Hiện các file đặc trưng ứng viên của S01 còn chưa có label; mốc KSS chưa căn chắc với raw, đặc biệt phiên 06 lệch giữa thời gian bạn xác nhận đo và thời lượng file lưu.

Việc của bạn và việc của phần mềm

Bạn đo đúng, ghi KSS thật, giờ và hoạt động thực tế, giữ dữ liệu gốc. Phần xử lý đọc file, lọc, đánh dấu vùng lỗi, tính đặc trưng và chuẩn bị dữ liệu sau khi đủ thông tin. Bạn không phải tự xem từng dòng hay tự tính phổ bằng tay.

SEED VIG là nhánh dữ liệu khác

SEED-VIG đã có dữ liệu thật trên máy, với đặc trưng và nhãn PERCLOS liên tục. PERCLOS khác KSS. Không lấy kết quả trên bộ này để nói thiết bị NeuroSky tự thu đạt cùng độ chính xác. Cần giữ hai thí nghiệm riêng.

Bạn chưa cần học mọi chi tiết trên trang này ngay. Hãy quay lại khi đã phân biệt rõ dữ liệu, đặc trưng, nhãn, tập học và tập kiểm tra.

15 Bài tập nhập môn

Hãy trả lời bằng lời của bạn trước. Chỉ dùng kiến thức trong tài liệu; không cần máy tính hoặc mã Python. Đáp án ở hai trang tiếp theo.

Nhóm 1 về các từ cơ bản

1. “Dữ liệu”, “mô hình” và “dự đoán” có giống nhau không? Cho một ví dụ trái cây để phân biệt.

2. Trong bảng gồm mã quả, cân nặng và tên quả: chọn đặc trưng và nhãn cho bài đoán tên quả.

3. Đoán tên loại quả là phân loại hay hồi quy? Đoán giá căn phòng là gì?

4. Sao chép một hàng dữ liệu thành 100 hàng có nghĩa đã đo 100 vật khác nhau không?

Nhóm 2 về học và kiểm tra

5. Vì sao không nên học trên toàn bộ ví dụ rồi dùng lại đúng các ví dụ đó để kết luận mô hình dùng tốt cho ví dụ mới?

6. Với bảng trang 3, dùng láng giềng gần nhất để đoán quả 170 gam. Dự đoán có chắc chắn đúng không?

7. Có 95 mẫu tỉnh và 5 mẫu buồn ngủ, máy luôn đoán tỉnh. Accuracy và recall buồn ngủ bằng bao nhiêu?

8. Máy đoán buồn ngủ nhưng thực tế tỉnh là báo nhầm hay bỏ sót? Máy đoán tỉnh khi thực tế buồn ngủ thì sao?

Nhóm 3 liên hệ với đồ án

9. 4 giây EEG tại 512 Hz có bao nhiêu giá trị raw? Chúng có phải 2.048 người không?

10. Một người có sáu file đo. Có được gọi là sáu người để làm kiểm tra theo người không?

11. Đã lọc xong 1.291 cửa sổ nhưng chưa có nhãn. Có thể kết luận đã có 1.291 ví dụ học có đáp án chưa?

12. Nếu KSS là nguồn tạo đáp án tỉnh/buồn ngủ, có nên đưa chính KSS vào X để máy đoán đáp án đó không?

16 Đáp án bài 1 đến bài 6

Bài 1

Không giống nhau. Dữ liệu là các số đo và tên quả đã ghi. Mô hình là cách dự đoán được tạo qua việc học. Dự đoán là câu trả lời khi mô hình nhận một quả, chẳng hạn đoán Táo cho quả 110 gam. Câu trả lời có thể sai.

Bài 2

Đặc trưng trong ví dụ đầu là cân nặng. Nhãn là tên quả. Mã quả để tra lại dữ liệu. Không đưa tên quả vào đầu vào rồi chấm khả năng đoán tên, vì như vậy máy đã thấy đáp án.

Bài 3

Đoán tên loại quả là phân loại: đầu ra là một lớp. Đoán giá là hồi quy: đầu ra là một giá trị số. Dùng số 0/1 để mã hóa tên lớp không tự biến phân loại thành hồi quy.

Bài 4

Không. Sao chép chỉ tạo thêm bản lặp của cùng thông tin. Muốn có thêm bằng chứng từ vật hoặc người khác phải thu dữ liệu thật của các đối tượng đó. Trong EEG, nhiều cửa sổ còn có thể dùng chung tín hiệu nếu chồng lấn.

Bài 5

Mô hình có thể nhớ ví dụ đã học. Điểm trên train không đủ cho kết luận về dữ liệu chưa gặp. Giữ test riêng giúp đặt một câu hỏi khác: với đầu vào chưa được phép học, máy làm tốt đến đâu? Khi chọn cấu hình nhiều lần, cần tổ chức validation phù hợp nữa.

Bài 6

Dự đoán Cam: hai cân nặng gần 170 nhất là 160 và 180, đều mang nhãn Cam. Không chắc đúng; nếu quả thật là táo lớn thì mô hình sai. Ví dụ này cũng cho thấy cân nặng có thể chưa đủ thông tin để nhận dạng mọi quả.

Nếu bạn giải thích được các đáp án bằng lời khác mà vẫn đúng ý, bạn đã hiểu tốt hơn việc chỉ thuộc định nghĩa. Hãy thử thay 170 bằng 90 rồi tự giải lại: gần 80 và 100, cả hai đều là Táo trong bảng minh họa.

17 Đáp án bài 7 đến bài 12

Bài 7

Accuracy = 95/100 = 95%. Recall buồn ngủ = 0/5 = 0%, vì không bắt đúng mẫu buồn ngủ nào. Do đó 95% đúng chung không bảo đảm hệ thống phát hiện được điều quan trọng.

Bài 8

Đoán buồn ngủ khi thực tế tỉnh là báo nhầm, ký hiệu FP. Đoán tỉnh khi thực tế buồn ngủ là bỏ sót, ký hiệu FN. Hai lỗi có ý nghĩa khác nhau; cần nhìn cả hai khi đánh giá ứng dụng.

Bài 9

4 × 512 = 2.048 giá trị raw. Đây là các giá trị tín hiệu theo thời gian, không phải số người. Trong một cách xử lý, toàn bộ 4 giây được mô tả bằng một hàng đặc trưng, tức một mẫu ML ở cấp cửa sổ.

Bài 10

Không. Vẫn chỉ một người thật. Sáu phiên giúp xem biến thiên qua lần đo nhưng không thay thế sáu người. Đổi mã một phiên thành người mới sẽ làm sai ý nghĩa kiểm tra khả năng áp dụng cho người khác.

Bài 11

Chưa. Bạn mới có đặc trưng ứng viên. Học có giám sát còn cần nhãn đã xác minh cho các khoảng phù hợp. Lọc không tạo nhãn. Không tự thêm 0 hoặc 1 vào mọi hàng chỉ để phần mềm cho huấn luyện.

Bài 12

Không. Mô hình sẽ được nhìn nguồn tạo đáp án và có thể làm bài kiểm tra cao giả. Khi sử dụng thực tế, ta muốn nó suy từ tín hiệu EEG, không phải nhận KSS rồi trả lại nhãn do KSS tạo ra. KSS dùng xây dựng và kiểm tra nhãn theo quy trình.

Tự đánh giá việc hiểu bài

Nếu còn nhầm dữ liệu với mô hình, quay lại trang 2–4. Nếu còn cho rằng điểm train đủ chứng minh, quay lại trang 9–11. Nếu còn nhầm dòng raw với mẫu ML hoặc số người, đọc lại trang 13–14 trước khi làm việc trên app.

18 Từ điển nhỏ và bài học tiếp theo

Từ	Nghĩa dễ nhớ
Data / dataset	Dữ liệu / bộ dữ liệu
Sample	Một ví dụ; phải biết nó đại diện cho gì
Feature	Đặc trưng đầu vào
Label	Đáp án tham khảo
Model	Mô hình dùng để dự đoán
Training / fit	Huấn luyện / thao tác học
Prediction / predict	Dự đoán / thao tác dự đoán
Classification	Phân loại vào các lớp
Regression	Dự đoán giá trị số
Train / test	Phần học / phần kiểm tra
Overfitting	Bám quá mức dữ liệu học
Data leakage	Dùng thông tin đáng ra chưa được biết
Accuracy	Tỷ lệ dự đoán đúng chung
Precision / recall	Độ đúng trong các lần báo / mức bắt được lớp cần phát hiện
Pipeline	Chuỗi các bước xử lý ghép với mô hình

Sau tài liệu này học gì

Học Python tối thiểu và cách đọc bảng; sau đó thực hành một bài nhỏ có dữ liệu minh họa. Khi làm được, dùng tài liệu “Tự học ML cho đồ án EEG N16” để học sâu hơn về đặc trưng phổ, chuẩn hóa, LOSO, ma trận nhầm lẫn và phần mềm của nhóm.

Nguồn học chính thức để tra sau: scikit-learn.org/stable — phần Getting Started và Common pitfalls. Không cần bắt đầu bằng toàn bộ tài liệu API. Hồ sơ dữ liệu dự án được tham khảo từ báo cáo xử lý S01 và hồ sơ SEED-VIG trong thư mục docs/output của da1.

Điều cần nhớ nhất: hiểu đầu vào, đáp án và cách kiểm tra trước khi chạy mô hình. Chương trình chạy xong chưa có nghĩa mô hình đã được chứng minh đúng.