01 Học ML để hiểu và làm đồ án N16

Từ file EEG đến mô hình phát hiện buồn ngủ

Dành cho sinh viên Kỹ thuật máy tính bắt đầu học ML. Cập nhật nội dung theo mã và hồ sơ dữ liệu đã kiểm tra đến ngày 03/11/2026.

Sau khi học, bạn cần giải thích được một mẫu ML là gì, nhãn lấy ở đâu, vì sao lọc chưa đủ để huấn luyện, cách đánh giá theo người và cách đọc kết quả. Bạn không cần thuộc tất cả công thức trước khi thao tác phần mềm.

Bài toán của bạn

Đầu vào là EEG đơn kênh NeuroSky 512 Hz. Từ mỗi khoảng tín hiệu, hệ thống tính đặc trưng phổ EEG và đặc trưng liên quan chớp mắt, rồi dự đoán tỉnh táo hoặc buồn ngủ. Nhãn tham khảo được xây dựng từ KSS và quy trình thí nghiệm đã thống nhất.

Đọc theo thứ tự trang 2–10 để hiểu nền tảng; trang 11–15 để áp dụng; trang 16–18 để làm bài tập và tự kiểm tra. Trang 19–20 giúp chuẩn bị báo cáo và tìm nguồn học tiếp.

Chặng học khi rảnh	Nội dung	Tự làm được sau chặng
1	Trang 2–4	Phân biệt raw, cửa sổ và đặc trưng
2	Trang 5–7	Hiểu nhãn và cách chia dữ liệu
3	Trang 8–10	Hiểu mô hình và chỉ số
4	Trang 11–15	Đọc đúng app, mã và trạng thái dự án
5	Trang 16–18	Tự tính và sửa lỗi tư duy
6	Trang 19–20	Trả lời câu hỏi của GVHD

Mọi bảng mang tên “minh họa” là số liệu để học, không phải kết quả thực nghiệm của nhóm. Đến hồ sơ xử lý đang dùng, chưa có accuracy/F1 thật của bộ S01 hoặc SEED-VIG được xác nhận.

02 Một mẫu ML khác một dòng raw

ML là học quy luật từ các ví dụ. Trong học có giám sát, mỗi ví dụ có đầu vào X và đáp án y. Với N16, X là các đặc trưng tính từ một cửa sổ EEG; y là nhãn tỉnh hoặc buồn ngủ đã được xác minh.

Khái niệm	Ví dụ trong N16
Một giá trị raw	Một giá trị Electrode tại một thời điểm
Tần số 512 Hz	Mỗi giây có 512 giá trị raw
Một cửa sổ 4 giây	Gồm 4 × 512 = 2.048 giá trị raw
Một mẫu ML	Một hàng đặc trưng đại diện cho cửa sổ
Một phiên	Một lần ghi CSV có nhật ký riêng
Một người	S01 vẫn là S01 dù có sáu phiên

Ví dụ tính số cửa sổ

Có đúng 60 giây dữ liệu liên tục. Nếu dùng cửa sổ dài 4 giây, bước 4 giây, ta có 15 cửa sổ không chồng lấn. Nếu bước chỉ 1 giây, ta có 57 cửa sổ, vì cửa sổ cuối bắt đầu ở giây 56 và kết thúc ở giây 60.

$$Số\ cửa\ sổ\ trước\ làm\ tròn\ xuống\ = \frac{T\ -\ W}{S}$$

Lấy phần nguyên xuống của (T − W)/S rồi cộng 1, với T ≥ W. T là độ dài bản ghi, W là độ dài cửa sổ, S là bước trượt, cùng đơn vị giây. Nếu có vùng lỗi hoặc nhãn thiếu, số cửa sổ được giữ sẽ ít hơn.

Vì sao nhiều cửa sổ chưa chắc nhiều thông tin

Hai cửa sổ [0,4) và [1,5) dùng chung 3 giây, tức 75% dữ liệu. Chúng không phải hai lần đo độc lập. Tăng overlap tạo nhiều hàng hơn nhưng không tạo thêm người hoặc thêm thời gian ghi thật.

Tự hỏi: 2.048 điểm raw luôn là 4 giây không? Không. Chỉ đúng ở 512 Hz; tại 256 Hz, số điểm đó phủ 8 giây.

03 Đọc đúng CSV của bạn

CSV OpenViBE của bạn gồm một kênh raw, tám chỉ số công suất và các cột kỹ thuật. Trước khi học mô hình, phải hiểu mỗi cột biểu diễn gì. [N1, N2]

Cột	Ý nghĩa	Có dùng làm X trực tiếp không
Time:512Hz	Giây tính từ đầu bản ghi	Không đưa vào mô hình chỉ để đoán giờ
Epoch	Chỉ số khối OpenViBE	Không
Electrode	EEG raw một kênh, count theo đường thu đã kiểm tra	Cần lọc và tính đặc trưng trước
Delta … Mid Gamma	Tám công suất từ thiết bị/SDK	Có thể làm nhánh nghiên cứu riêng
Event Id/Date/Duration	Mốc sự kiện nếu đã ghi	Không có nghĩa là nhãn khi đang trống

Điểm dễ nhầm về đơn vị

Trong cấu hình đã đối chiếu với driver OpenViBE 3.6.0, Electrode được giữ ở raw count. Con số 118.0000000000 vẫn là 118 count; cách in số thập phân không chứng minh đơn vị µV. Không trộn đặc trưng tính từ count với µV như thể chúng cùng thang đo.

Tám công suất không phải tám điện cực. Trong bản ghi đã kiểm tra, chúng đổi khoảng một lần mỗi giây và lặp lại giữa các lần cập nhật. Đừng đếm 512 dòng lặp thành 512 phép đo công suất độc lập.

CSV đủ cấu trúc chưa có nghĩa sạch

Không có ô trống chỉ chứng minh các giá trị đã được lưu. Tín hiệu vẫn có thể chứa nhiễu lưới điện, chuyển động hoặc cắt đỉnh. Trục thời gian đều do phần mềm xuất cũng chưa chứng minh Bluetooth không mất gói.

Bài tập nhanh: có 399.392 dòng ở 512 Hz thì thời lượng là 780,0625 giây, khoảng 13 phút. Không kéo giãn thành 15 phút chỉ để khớp nhật ký.

04 Đặc trưng là bản mô tả một cửa sổ

Một cửa sổ có 2.048 giá trị raw. Đặc trưng nén cửa sổ thành một số đại lượng mô tả, giúp mô hình cổ điển học trên bảng dữ liệu gọn hơn. Không có một đặc trưng nào tự động là bằng chứng chắc chắn của buồn ngủ.

Đặc trưng	Giải thích dễ hiểu	Giới hạn cần nhớ
abs_theta, abs_alpha	Công suất trong dải theta hoặc alpha	Phụ thuộc đơn vị và chất lượng tín hiệu
rel_theta	Công suất theta chia tổng công suất quy định	Phải công bố dải của tổng
theta_alpha	Công suất theta chia công suất alpha	Mẫu số nhỏ có thể làm tỷ số rất lớn
spectral_entropy	Mức phân tán của công suất trên tần số	Không phải entropy của nhãn
blink_rate_per_min	Số sự kiện chớp ước lượng quy ra một phút	Cửa sổ ngắn gây biến động lớn
blink_width_mean	Độ rộng trung bình sự kiện ước lượng	Chưa tương đương thời gian mắt đóng thật

Ví dụ minh họa

Cửa sổ A có công suất theta = 12, alpha = 6, tổng công suất = 40. Khi đó theta/alpha = 2 và công suất theta tương đối = 12/40 = 0,30. Đây là ví dụ toán học, không phải ngưỡng “lớn hơn 2 là buồn ngủ”.

Nếu thuật toán đếm một chớp trong 4 giây, tốc độ quy đổi là 1 × 60/4 = 15 chớp/phút. Đó là phép quy đổi từ khoảng quan sát ngắn; không có nghĩa người đó thực sự chớp đúng 15 lần trong một phút đã đo.

Hai nhánh phải giữ mục đích riêng

Nhánh phổ muốn giảm artifact để mô tả EEG. Nhánh chớp mắt cần giữ thông tin liên quan mắt. Không xóa hết xung mắt trước cả hai nhánh rồi mong vẫn đếm chớp tốt. Trong bộ xử lý S01, đặc trưng phổ dùng bản lọc; blink ước lượng vẫn lấy từ raw tại cửa sổ ứng viên.

05 Lọc và sàng lọc trước khi học

Lọc thay đổi thành phần tần số. Sàng lọc quyết định đoạn nào bị gắn cờ hoặc cần xem thêm. Hai việc này khác với gán nhãn tỉnh/buồn ngủ: một đoạn sạch có thể thuộc bất kỳ trạng thái nào.

Hiện tượng	Xử lý trong bản ngoại tuyến S01	Không được suy ra
Thành phần gần 50 Hz	Notch 50 Hz và thông dải 0,5–45 Hz	Không mặc định toàn bộ năng lượng đó là EEG
Chạm/vượt biên dự kiến	Đánh dấu cửa sổ 4 giây chứa lỗi	Không cắt vài mẫu rồi nối thời gian lại
Giữ nguyên ≥0,25 giây	Đánh dấu vùng cửa sổ liên quan	Không tự kết luận mất Bluetooth
Đầu/cuối đoạn lọc	Giữ vùng biên để kiểm tra riêng	Không gọi phần còn lại chắc chắn sạch

Điều đã làm trên dữ liệu của bạn

Bộ xử lý sáu phiên tạo bản lọc riêng bằng notch và Butterworth hai chiều. Nó không bù mẫu lỗi, không gán nhãn KSS và giữ nguyên raw gốc. Bộ lọc hai chiều dùng thông tin tương lai nên chỉ dùng ngoại tuyến; không dùng thời gian chạy của nó để chứng minh cảnh báo trực tiếp dưới 3 giây.

Sau sàng lọc và tránh biên lọc còn 1.291 cửa sổ không chồng lấn, tức 86 phút 4 giây. Đây là phần ứng viên để xem nhãn tiếp, chưa phải dữ liệu huấn luyện đã được xác nhận. [N3]

Lọc không thể sửa mọi thứ

Khi tín hiệu đã bị cắt đỉnh, biên độ thật phía ngoài giới hạn không còn trong file. Bộ lọc chỉ có thể biến đổi giá trị đã lưu, không khôi phục chắc chắn thông tin đã mất. Cũng không thể tạo thêm hai phút thiếu trong phiên 06 bằng nội suy.

Lưu ý mã: app tạo đặc trưng hiện dùng mask FFT và periodogram Hann; bản xử lý hàng loạt dùng bộ lọc SOS ngoại tuyến. Khi báo cáo hoặc so sánh mô hình, phải cố định một nhánh xử lý, không trộn chúng như cùng phương pháp.

06 Nhãn KSS là đáp án tham khảo

Học có giám sát cần đáp án y. Máy không tự biết bạn buồn ngủ lúc nào chỉ vì file được đặt tên PILOT_04. KSS là điểm bạn tự đánh giá tại các mốc thực tế; quy tắc quy điểm thành khoảng nhãn phải được xác nhận trước thực nghiệm.

KSS	Quy ước hai lớp hiện có trong mã N16
1 đến 5	Nhãn 0 — phía tỉnh táo
6	Không dùng trong bài toán hai lớp hiện tại
7 đến 9	Nhãn 1 — phía buồn ngủ

Đây là quy tắc dự án cần chốt với GVHD, không phải ngưỡng do SEED-VIG hoặc giao thức ThinkGear quy định. Vẫn ghi KSS 6 thật; không đổi thành 5 hoặc 7 để đủ lớp.

Điểm KSS khác khoảng nhãn

Bạn chấm KSS 7 lúc 23:38. Điều đó chưa tự chứng minh mọi mẫu từ 23:33 đến 23:38 đều có nhãn 1. Có thể chọn một khoảng trước lần chấm, nhưng độ dài, vùng trả lời và cách xử lý chuyển trạng thái phải nằm trong quy trình nhất quán.

Ví dụ minh họa căn thời gian: CSV bắt đầu đúng 23:33:20, một lần chấm bắt đầu 23:38:20 thì mốc đó ở raw 300 giây. Nếu quy tắc đã chốt dùng 60 giây trước chấm và đoạn đạt chất lượng, khoảng [240,300) mới là ứng viên. Các giờ chính xác này chỉ là ví dụ, không phải giờ đã khôi phục của bạn.

Khi chỉ nhớ đến phút

Ghi 23:33 không đồng nghĩa 23:33:00. Không tự thêm giây để làm nhãn chính xác giả. Phiên 06 có CSV khoảng 13 phút dù bạn xác nhận đo 15 phút; chưa rõ lệch ở đầu, giữa hay cuối, nên không ép điểm phút 15 vào mẫu cuối.

Trong file khoảng nhãn của app, usable chỉ dùng sau khi đã kiểm tra cả căn nhãn và chất lượng; exclude là loại; unknown là chưa xác minh. Bộ 1.291 cửa sổ hiện chưa có label vì bước này chưa hoàn tất.

07 Chia dữ liệu để kiểm tra đúng điều cần biết

Tập học giúp mô hình tìm tham số. Tập xác thực giúp chọn cấu hình. Tập kiểm tra dùng đánh giá sau khi đã khóa lựa chọn. Nếu bạn dùng điểm test để sửa mô hình nhiều lần, test dần trở thành một phần quá trình chọn mô hình.

Câu hỏi muốn trả lời	Cách chia phù hợp
Mô hình có nhớ ví dụ đã học không	Điểm train chỉ mô tả độ khớp, chưa đủ đánh giá
S01 ngày khác có còn dùng được không	Giữ nguyên một phiên/ngày để kiểm tra, tránh chồng cửa sổ
Người mới có dùng được không	Giữ nguyên một người chưa xuất hiện trong tập học
Đổi đặc trưng/mô hình nào tốt hơn	Chọn trên validation hoặc vòng bên trong; giữ test ngoài độc lập

LOSO nghĩa là gì

Leave-One-Subject-Out: lần lượt giữ toàn bộ dữ liệu của một người làm test, học trên những người còn lại. Trong scikit-learn, dự án dùng LeaveOneGroupOut với groups = subject_id. [S1]

Lượt với ba người minh họa	Tập học	Tập kiểm tra
1	S02 và S03	S01
2	S01 và S03	S02
3	S01 và S02	S03

Hiện sáu phiên tự thu đều là S01. Đổi tên phiên thành S02 không tạo người thứ hai. Hai người có thể tạo hai lượt LOSO nhưng kết luận còn rất hạn chế; tập học từng lượt phải có đủ hai lớp.

Cửa sổ chồng lấn dễ làm kết quả cao giả

Nếu [0,4) nằm ở train và [1,5) nằm ở test, mô hình đã nhìn phần lớn dữ liệu test trong quá trình học. Chia theo người/phiên trước và giữ các đoạn chồng nhau ở cùng phía. Ngay cả cửa sổ không chồng lấn liền kề vẫn có phụ thuộc theo thời gian.

08 Chuẩn hóa và tránh rò rỉ dữ liệu

Các đặc trưng có thang đo khác nhau. Công suất có thể hàng nghìn, còn công suất tương đối thường nhỏ hơn 1. StandardScaler đưa mỗi cột về thang dựa trên trung bình và độ lệch chuẩn của tập học. Nó không lọc artifact và không tạo nhãn.

$$z = \frac{x - \mu_train}{\sigma_train}$$

Ví dụ minh họa: trong train, một cột có trung bình 10, độ lệch chuẩn 2. Giá trị x = 14 trở thành z = 2. Nếu test có x = 12, vẫn dùng hai số của train, nên z = 1. Không tính lại trung bình bằng cả test.

Vì sao fit trước khi chia là sai

Nếu fit scaler trên toàn bộ dữ liệu rồi mới tách người, thống kê của người test đã ảnh hưởng bước biến đổi. Dù nhãn test không được đưa vào trực tiếp, thiết kế đánh giá đã dùng thông tin ngoài tập học. Các bước chọn đặc trưng, impute hoặc PCA học từ dữ liệu cũng cần nằm trong phạm vi train. [S2]

```
# Mã minh họa scikit-learn
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression

model = make_pipeline(
    StandardScaler(),
    LogisticRegression(class_weight="balanced", max_iter=2000)
)
model.fit(X_train, y_train)
y_pred = model.predict(X_test)
```

Pipeline gọi fit scaler trên X_train, biến đổi train rồi học classifier. Khi predict X_test, nó dùng lại scaler đã học. Trong LOSO, phải tạo bản model mới cho mỗi lượt; mã hiện tại dùng clone để làm việc này.

Ba thông tin không được làm đặc trưng

KSS/perclos là nguồn tạo y, không đưa vào X để đoán chính y. subject_id chỉ giúp chia nhóm. session_id và thời gian có thể vô tình cho mô hình nhận ra buổi sáng/đêm thay vì tín hiệu EEG. Mã dự án chặn nhiều cột nhãn và metadata, nhưng bạn vẫn cần kiểm tra danh sách đặc trưng thực dùng.

09 Hiểu ba mô hình trong ứng dụng

Mô hình	Cách hiểu	Điều cần theo dõi
Logistic Regression	Cộng có trọng số các đặc trưng rồi đổi thành giá trị xác suất mô hình	Cần chuẩn hóa; quan hệ cơ bản là tuyến tính trên đặc trưng
SVM RBF	Tìm ranh giới phân biệt hai lớp trong không gian biến đổi	C và gamma ảnh hưởng độ khớp; score mặc định không phải xác suất
Random Forest	Nhiều cây đưa ra dự đoán, kết hợp các cây	Số cây và độ sâu; mô hình vẫn có thể học nhiễu

Một lần dự đoán logistic bằng số

Ví dụ hoàn toàn giả định: hai đặc trưng đã chuẩn hóa có giá trị x_1 = 1, x_2 = 0,5. Giả sử mô hình học được w_1 = 0,8; w_2 = 0,4 và b = −0,2. Tổng điểm là s = 0,8 × 1 + 0,4 × 0,5 − 0,2 = 0,8.

$$p = \frac{1}{1 + exp(-s)}$$

Với s = 0,8 thì p ≈ 0,690. Nếu ngưỡng đã chốt là 0,5, mô hình dự đoán lớp 1. Đây không phải xác nhận người đó chắc chắn buồn ngủ, cũng không phải kết quả từ dữ liệu của bạn. Xác suất mô hình còn cần đánh giá độ tin cậy. [S3]

Huấn luyện thực sự thay đổi gì

Hàm fit điều chỉnh tham số để các ví dụ train được dự đoán tốt hơn theo hàm mất mát và ràng buộc của mô hình. Hàm predict dùng tham số đã học, không tự biết nhãn thật của dữ liệu mới. Không nên hiểu ML là tìm một ngưỡng theta/alpha duy nhất áp cho mọi người.

Trong mã hiện tại, logistic và SVM dùng class_weight="balanced"; rừng có 200 cây, max_depth=8. Đây là cấu hình nền, không phải bằng chứng đã tối ưu. Cả ba được đặt sau StandardScaler trong Pipeline; dù rừng thường ít cần chuẩn hóa, phải mô tả đúng cấu hình đang chạy.

Bắt đầu bằng mô hình nền dễ kiểm tra. Đừng đổi ngay sang deep learning chỉ vì dữ liệu có nhiều dòng raw; số người, nhãn và cách chia mới quyết định mức bằng chứng bạn có.

10 Đọc kết quả bằng ma trận nhầm lẫn

Quy ước lớp 1 là buồn ngủ. Ví dụ dưới có 100 cửa sổ test độc lập với train; đây là số liệu minh họa để học tính toán. Trong dự án, ma trận dùng hàng là nhãn thật và cột là dự đoán. [S4]

Nhãn thật	Dự đoán tỉnh 0	Dự đoán buồn ngủ 1
Tỉnh 0	40 — TN	10 — FP
Buồn ngủ 1	15 — FN	35 — TP

Chỉ số	Tính trong ví dụ	Ý nghĩa
Accuracy	(40 + 35)/100 = 75%	Tỷ lệ đúng chung
Precision lớp 1	35/(35 + 10) = 77,78%	Trong các lần báo buồn ngủ, bao nhiêu lần đúng
Recall lớp 1	35/(35 + 15) = 70%	Trong các mẫu buồn ngủ thật, bắt được bao nhiêu
F1 lớp 1	2 × 35/(2 × 35 + 10 + 15) = 73,68%	Kết hợp precision và recall
Specificity	40/(40 + 10) = 80%	Nhận đúng phía tỉnh táo

Vì sao accuracy cao vẫn có thể tệ

Ví dụ có 950 cửa sổ tỉnh và 50 cửa sổ buồn ngủ. Máy luôn đoán tỉnh đạt accuracy 95%, nhưng recall buồn ngủ = 0%. Vì vậy phải xem FN, recall buồn ngủ và phân phối lớp, không chỉ nhìn một con số đẹp.

Macro-F1 là trung bình F1 các lớp. Trong ví dụ ma trận trên, F1 lớp 0 ≈ 76,19%, macro-F1 ≈ 74,94%. Đừng lấy F1 lớp 1 rồi ghi là macro-F1. AUC đo khả năng xếp hạng theo score, không phải accuracy; test chỉ có một lớp thì không tính được AUC hai lớp.

Đề N16 cần kiểm chứng chớp mắt và độ trễ riêng. Accuracy phân loại cửa sổ không tự chứng minh blink ≥90% hoặc cảnh báo <3 giây. Cửa sổ chồng lấn còn làm các quan sát phụ thuộc nhau, cần nêu rõ khi báo cáo.

11 Làm việc trên ứng dụng hiện tại

Mở D:\dh\da1\Mo_UngDung_ML.cmd. Bốn tab tương ứng bốn công việc khác nhau; nạp raw thành công chưa phải huấn luyện thành công.

Tab	Bạn xem hoặc nhập gì	Kết quả đúng mong đợi
1 Kiểm tra CSV	Chọn CSV gốc, xem loại file, thời lượng và biên độ	Biết file đọc được; chưa chứng nhận sạch
2 Tạo đặc trưng	Mã S01, mã phiên, count, khoảng nhãn/chất lượng đã xác minh	Tạo features.csv cùng hồ sơ xử lý
3 Huấn luyện	CSV đặc trưng có label, cùng nguồn và schema, đủ người	Mô hình, chỉ số từng người, dự đoán ngoài fold
4 SEED-VIG	MAT đặc trưng, manifest, ngưỡng PERCLOS đã chốt	Nhập nhánh SEED-VIG riêng

Tình trạng các tệp của S01

Trong output/processed_pilot/S01_batch_20261028_v1, feature_candidates_UNLABELED.csv chứa đặc trưng ứng viên chưa có label. Không đổi tên thành features.csv rồi kỳ vọng app biết nhãn. kss_observations_UNALIGNED.csv giữ điểm KSS nhưng raw_time_s còn trống; window_screening.csv giữ kết quả sàng lọc. [N3]

Nếu app báo lỗi thì đọc như thế nào

Thiếu label: cần hoàn tất căn nhãn, không thêm 0 cho mọi hàng. Chỉ có một người: chưa đủ LOSO theo người, không đổi một phiên thành người giả. NaN trong bản lọc: có thể là vùng đã đánh dấu loại, không tự điền 0 hoặc xóa thời gian. Sai nguồn: giữ NeuroSky và SEED-VIG thành hai thí nghiệm riêng.

Bạn chịu trách nhiệm ghi thông tin thực tế khi đo. Phần xử lý sẽ kiểm tra và tạo đầu vào có nhãn sau khi đủ bằng chứng; bạn không phải tự xem hàng trăm nghìn dòng hoặc tự tính phổ bằng tay.

12 Đọc mã Python mà không cần thuộc hết

Các dòng sau minh họa một lượt học và kiểm tra trên người được giữ lại. Chỉ chạy sau khi đã có bảng đặc trưng thật có nhãn hợp lệ; đoạn này không tự gắn nhãn các file ứng viên hiện tại.

```
import pandas as pd
from sklearn.base import clone
from sklearn.model_selection import LeaveOneGroupOut
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import confusion_matrix

# Đường dẫn minh họa; tệp phải được chuẩn bị hợp lệ trước.
df = pd.read_csv("features_da_xac_minh.csv")
cols = ["theta_alpha", "rel_theta", "rel_alpha"]
X = df[cols].to_numpy()
y = df["label"].to_numpy()
groups = df["subject_id"].astype(str).to_numpy()
assert df["subject_id"].nunique() >= 2
assert set(y) == {0, 1}

base = make_pipeline(StandardScaler(),
    LogisticRegression(class_weight="balanced", max_iter=2000))
for train, test in LeaveOneGroupOut().split(X, y, groups):
    if len(set(y[train])) < 2:
        print("Bo qua: tap hoc chi co mot lop")
        continue
    model = clone(base)
    model.fit(X[train], y[train])
    pred = model.predict(X[test])
    print(groups[test][0])
    print(confusion_matrix(y[test], pred, labels=[0, 1]))
```

Cách đọc từng khối

df là bảng. cols chọn đúng cột đầu vào; không chứa KSS hoặc label. train/test là vị trí các hàng theo nhóm người. clone tạo lượt mới. fit chỉ dùng train; predict chỉ nhận X test. y test chỉ dùng để chấm kết quả, không đi vào fit.

Mã sản phẩm còn kiểm tra NaN, đơn vị, nguồn, đủ lớp và lưu hồ sơ. Đoạn học tập rút gọn không thay thế các kiểm tra đó. Không dùng mã này để biến dữ liệu minh họa thành kết quả đồ án.

13 SEED VIG phục vụ phần nào của bài

SEED-VIG cung cấp đặc trưng EEG, EEG trán, EOG và nhãn PERCLOS. Đây là nhánh tham khảo/benchmark về mức tỉnh táo, có hệ đo và nhãn khác với raw NeuroSky tự thu. [V1]

Nguồn	Đầu vào đang có	Nhãn
S01 NeuroSky	Raw 512 Hz; đặc trưng do nhóm tính	KSS trong phiếu
SEED EEG 5Bands	17 × 885 × 5 cho một phiên; 85 đặc trưng khi trải phẳng	PERCLOS 885 × 1
SEED EEG trán	4 × 885 × 5; 20 đặc trưng	PERCLOS
SEED EOG	885 × 36; 36 đặc trưng mắt	PERCLOS

Hồ sơ cục bộ đã kiểm tra 23 phiên, mỗi phiên 885 hàng, tức 20.355 hàng cho mỗi nhánh. Các nhánh mô tả cùng các phiên, không cộng chúng thành ba lần số quan sát độc lập. [N4]

Vì sao chưa tự chạy phân loại

PERCLOS là số liên tục từ 0 đến 1. Muốn phân loại hai lớp phải xác định ngưỡng tỉnh và buồn ngủ có căn cứ, giữ vùng giữa hoặc loại theo quy tắc đã chốt. Không dùng KSS 7–9 làm ngưỡng PERCLOS. Nếu làm hồi quy, đầu ra vẫn là số liên tục và chỉ số có thể là RMSE/COR, khác accuracy.

Bản phát hành có 23 tên phiên nhưng 21 tiền tố số khác nhau; tiền tố 4 và 5 lặp. Chưa có bảng ánh xạ người được xác nhận trong hồ sơ hiện tại, nên manifest giữ REPLACE và alignment_verified=false. Không tự coi mỗi file là một người mới để có 23 fold.

Điều được phép kết luận

Chạy được mô hình trên SEED-VIG không chứng minh mô hình đó chạy đúng trên một kênh NeuroSky. Giữ benchmark riêng; nếu chuyển mô hình giữa thiết bị phải kiểm tra lại đặc trưng, đơn vị, vị trí đo và nhãn. Với dữ liệu đã làm trơn, còn cần kiểm tra tính nhân quả trước khi dùng cho cảnh báo trực tiếp.

14 Từ mô hình ngoại tuyến đến cảnh báo C cộng cộng

Bạn học CE nên cần hiểu cả khâu dữ liệu lẫn triển khai. Python phù hợp để khảo sát, huấn luyện và đánh giá; C++ có thể đảm nhiệm thu nhận, tính đặc trưng và suy luận trực tiếp. Chọn ngôn ngữ không thay thế kiểm chứng mô hình.

Khâu	Việc chính	Bằng chứng cần có
Huấn luyện Python	Fit scaler và mô hình trên train	Danh sách đặc trưng, tham số, fold và chỉ số
Suy luận C++	Tính cùng đặc trưng rồi áp tham số đã học	Đối chiếu cùng đầu vào giữa hai bản
Cảnh báo	Kết hợp score, ngưỡng và chính sách thời gian	Log kích hoạt và thời điểm âm thanh thật

Những thứ phải giống nhau

Thứ tự đặc trưng, đơn vị count/µV, tần số, độ dài/bước cửa sổ, lọc, chuẩn hóa và tham số mô hình phải phù hợp. Nếu Python tạo cột [theta_alpha, rel_theta] mà C++ đưa [rel_theta, theta_alpha], cùng hai số nhưng đầu ra có thể khác hoàn toàn.

Pipeline scikit-learn hiện lưu joblib cho nhánh ngoại tuyến. Runtime C++ đang dùng định dạng JSON của nhánh cũ; joblib không tự biến thành JSON đó. Chưa có bằng chứng hai nhánh tương đương chỉ vì đều mang tên logistic regression.

Độ trễ cần được định nghĩa và đo

Một bước trượt 1 giây không bảo đảm cảnh báo dưới 3 giây. Tổng trễ liên quan thu/truyền, phần tín hiệu cần chờ, lọc, tính đặc trưng, suy luận, chính sách xác nhận và phát âm thanh. Cửa sổ 4 giây cần phân biệt độ trễ khởi động với độ trễ quyết định khi đã có bộ đệm.

Đề N16 cần đo cảnh báo thật; thời gian predict vài mili giây chỉ là một khâu. Lọc hai chiều ngoại tuyến dùng mẫu tương lai, nên không đem trực tiếp kết quả đó làm bằng chứng đáp ứng thời gian thực. Khi chuyển sang bộ lọc nhân quả, phải đánh giá lại mô hình.

15 Hiểu trạng thái dữ liệu hiện tại

Phiên	KSS đã ghi	Cửa sổ ứng viên 4 giây
01	5, 5, 4	227
02	3, 3, 3, 3	221
03	2, 2, 3, 3	223
04 ngày 27/10	8, 9, 9, 9	207
05	7, 7, 7, 7	221
06	7, 8, 8, 8	192

Tổng 1.291 cửa sổ = 5.164 giây = 86 phút 4 giây. Nhóm phiên 01–03 có 671 cửa sổ; nhóm 04–06 có 620. Đây là nhóm theo điểm KSS của phiên, chưa phải phân phối label đã gán cho từng cửa sổ. [N3]

Việc hoàn tất và việc còn thiếu

Đã đọc dữ liệu, lọc, sàng lọc lỗi rõ và tạo đặc trưng ứng viên. Còn xác minh căn thời gian KSS, kiểm tra chất lượng ngoài các quy tắc tự động, chốt khoảng nhãn và dữ liệu người khác. Phiên 01 thiếu điểm cuối; phiên 06 có lệch thời lượng chưa giải thích.

Không có số mẫu cố định bảo đảm “đủ ML”. Số cửa sổ, số người, số phiên, hai lớp và độ tin cậy nhãn đều quan trọng. Mục tiêu số phút hoặc số phiên từng đề xuất là kế hoạch thu thử, không phải chuẩn nghiệm thu.

Một thứ tự làm có ý nghĩa

1. Giữ raw và nhật ký thật. 2. Chốt quy tắc nhãn, căn mốc và vùng chất lượng. 3. Tạo tập feature có label. 4. Chọn thiết kế split phù hợp với câu hỏi. 5. Fit trong train, báo điểm từng người/phiên. 6. Kiểm chứng blink và demo cảnh báo riêng.

Bạn không phải tự lọc bằng tay. Điều phần mềm không thể thay bạn là xác nhận đã làm gì lúc đo và điểm tự cảm nhận thật. Thông tin quên thì ghi thiếu; không tạo thêm sự chắc chắn chỉ để phần mềm cho chạy.

16 Bài tập tự làm trước khi xem đáp án

Các câu dưới dùng dữ liệu minh họa hoặc thông số đã biết của dự án. Dành một lượt học để làm trên giấy; chưa cần mở ứng dụng.

Nhóm A về dữ liệu

1. Một cửa sổ dài 4 giây ở 512 Hz có bao nhiêu điểm raw? Nếu đổi sang 256 Hz nhưng giữ 4 giây thì bao nhiêu điểm?

2. Với 60 giây liên tục, cửa sổ 4 giây: tính số cửa sổ khi bước 4 giây và khi bước 1 giây. Vì sao trường hợp sau không có thêm 42 lần đo độc lập?

3. Cửa sổ có theta=15, alpha=5, tổng=50. Tính theta/alpha và rel_theta. Có thể kết luận buồn ngủ chỉ vì tỷ số bằng 3 không?

4. Bảng có subject_id, session_id, kss, label, theta_alpha, rel_alpha, window_start_ms. Chọn các cột X phù hợp cho ví dụ này và giải thích vai trò các cột còn lại.

Nhóm B về học và đánh giá

5. Scaler của train có μ=8 và σ=2. Tính z cho test x=12. Có được fit lại scaler bằng test không?

6. Có S01 và S02, mỗi người có cả hai lớp. Hãy ghi hai lượt LOSO. Nếu S02 chỉ có lớp tỉnh thì lượt nào không học được classifier hai lớp?

7. Một ma trận có TN=40, FP=10, FN=15, TP=35. Tính accuracy, precision/recall/F1 của lớp buồn ngủ. FN trong ứng dụng là tình huống gì?

8. Có 950 mẫu tỉnh và 50 mẫu buồn ngủ. Luôn đoán tỉnh thì accuracy và recall buồn ngủ bằng bao nhiêu?

Nhóm C về đồ án của bạn

9. CSV có 399.392 mẫu tại 512 Hz, nhưng nhật ký ghi đo 15 phút. Nêu kết quả tính thời lượng và hai điều không được tự làm để “sửa cho khớp”.

10. Có 1.291 cửa sổ ứng viên sau lọc nhưng chưa có label. Có thể bấm Huấn luyện + LOSO cho S01 không? Nêu hai lý do độc lập.

11. Một mô hình đạt 90% trên SEED-VIG. Có được ghi NeuroSky của nhóm đạt 90% không?

12. SVM trả decision_function=0,8; logistic trả predict_proba=0,8. Có thể gọi cả hai là xác suất buồn ngủ 80% không?

17 Đáp án và giải thích bài 1 đến bài 6

Bài 1

4 × 512 = 2.048 điểm; 4 × 256 = 1.024 điểm. Độ dài thời gian phụ thuộc cả số điểm lẫn tần số. Đây là lý do không sao chép số mẫu/cửa sổ giữa NeuroSky và tài liệu dùng tần số khác.

Bài 2

Bước 4 giây: (60−4)/4 + 1 = 15 cửa sổ. Bước 1 giây: (60−4)/1 + 1 = 57. Nhiều cửa sổ dùng chung các mẫu raw; tổng thời gian thu vẫn chỉ 60 giây, số người vẫn không đổi.

Bài 3

theta/alpha = 15/5 = 3. rel_theta = 15/50 = 0,30. Không có cơ sở lấy số 3 làm ngưỡng buồn ngủ chung. Cần mô hình/quy tắc đã học hoặc chốt từ train, chất lượng tín hiệu và đánh giá độc lập. Nhắm mắt hay artifact cũng có thể làm đặc trưng đổi.

Bài 4

Trong danh sách cho trước, X có thể chọn theta_alpha và rel_alpha. label là đáp án y. subject_id dùng chia nhóm; session_id dùng truy xuất phiên; kss là nguồn tạo nhãn; window_start_ms dùng căn thời gian. Nếu đưa kss vào X để dự đoán nhãn do chính KSS tạo ra, bài toán bị lộ đáp án.

Bài 5

z = (12−8)/2 = 2. Không fit scaler lên test; dùng thống kê train. Trong LOSO, mỗi lượt có tập train khác nhau nên scaler được fit lại trên train của chính lượt đó, không dùng cùng một scaler fit toàn bộ người.

Bài 6

Lượt 1: train S01, test S02. Lượt 2: train S02, test S01. Nếu S02 chỉ có lớp tỉnh, lượt 2 không đủ hai lớp để học classifier hai lớp. Lượt 1 vẫn có thể dự đoán test một lớp, nhưng AUC hai lớp không xác định ở test đó; không âm thầm xóa lượt khỏi báo cáo.

Điểm cần nhớ: sửa một lỗi về phương pháp trước khi tìm mô hình phức tạp hơn thường có giá trị hơn tăng thêm vài tham số. Khi không đủ điều kiện tính chỉ số, ghi không tính được và lý do thay vì tự thay bằng 0.

18 Đáp án và giải thích bài 7 đến bài 12

Bài 7

Accuracy = 75%. Precision buồn ngủ = 35/45 ≈ 77,78%. Recall = 35/50 = 70%. F1 = 70/95 ≈ 73,68%. FN=15 là 15 cửa sổ buồn ngủ thật nhưng mô hình dự đoán tỉnh. Không chuyển 15 cửa sổ thành 15 cơn ngủ gật hoặc 15 sự kiện bỏ sót: đơn vị đánh giá đang là cửa sổ.

Bài 8

Accuracy = 950/1.000 = 95%. Recall buồn ngủ = 0/50 = 0%. Kết quả chứng minh cần xem chỉ số theo lớp. Class_weight có thể giúp mô hình chú ý lớp ít hơn trong train, nhưng không thay thế dữ liệu hoặc bảo đảm hiệu năng.

Bài 9

399.392/512 = 780,0625 giây = 13 phút 0,0625 giây. Không kéo giãn timestamp thành 15 phút và không tự chèn hai phút giả. Giữ cả xác nhận đo 15 phút và thời lượng lưu được để điều tra; CSV chưa đủ chứng minh nguyên nhân là nhiễu, mất kết nối hay thao tác.

Bài 10

Chưa. Thứ nhất, thiếu label có căn cứ theo từng khoảng; mô hình học có giám sát chưa có đáp án. Thứ hai, chỉ có một người thật nên chưa làm LOSO theo người. Ngoài ra, cửa sổ “không bị sàng lọc gắn cờ” chưa được xác nhận hết artifact.

Bài 11

Không. Khác thiết bị, vị trí/kênh, cách tính đặc trưng, quần thể và nhãn. Chỉ được báo kết quả trên SEED-VIG theo thiết kế đã thực hiện. Phải thực nghiệm riêng để có số liệu cho NeuroSky của nhóm, và phân biệt ngoại tuyến với cảnh báo trực tiếp.

Bài 12

Không. decision_function là điểm quyết định; 0,8 không có nghĩa 80%. predict_proba là xác suất do mô hình ước lượng, vẫn chưa bảo đảm hiệu chuẩn hoặc đúng trên người mới. Nếu đổi ngưỡng cảnh báo, chọn theo train/validation và mục tiêu trước khi chấm test.

Nếu còn nhầm từ ba câu trở lên, đọc lại trang tương ứng rồi tự giải lại bằng bộ số khác. Mục tiêu là giải thích được vì sao, không chỉ chép đúng kết quả số.

19 Tập trình bày với giảng viên hướng dẫn

Tại sao chọn ML cổ điển

Trả lời gợi ý: “Nhóm bắt đầu với Logistic Regression, SVM và Random Forest vì đầu vào là bảng đặc trưng, dễ kiểm tra pipeline và chi phí suy luận phù hợp. Nhóm chưa coi số dòng raw là bằng chứng đủ dữ liệu cho mô hình sâu.”

Nhãn của em lấy ở đâu

“Dữ liệu tự thu dùng KSS ghi thực tế theo mốc. Nhóm phải chốt quy tắc ánh xạ và khoảng đại diện; điểm chưa căn thời gian không tự gán vào toàn bộ phiên. SEED-VIG dùng PERCLOS và được đánh giá riêng.”

Em làm gì để tránh rò rỉ

“Chia theo người cho câu hỏi người mới; scaler nằm trong Pipeline và được fit riêng trong train từng lượt. Không dùng ID, nhãn hoặc KSS làm đặc trưng. Các cửa sổ chồng nhau không chia sang hai phía.”

Số 86 phút có nghĩa gì

“Đó là thời lượng của 1.291 cửa sổ ứng viên sau một bộ quy tắc sàng lọc và tránh biên lọc. Chưa phải 86 phút dữ liệu sạch có nhãn đã xác nhận; nhóm chưa báo accuracy/F1 từ bộ này.”

Làm sao chứng minh blink và độ trễ

“Blink cần nguồn đối chiếu độc lập và ghép từng sự kiện, báo bắt đúng/bỏ sót/báo nhầm. Độ trễ cần đo từ mốc đầu vào phù hợp đến cảnh báo thật. Hai yêu cầu này không được thay bằng accuracy cửa sổ hoặc thời gian model.predict.”

Những câu không nên viết khi chưa có bằng chứng

Không ghi “đã đạt 90%”, “đã đủ dữ liệu”, “không mất gói”, “mô hình chạy tốt mọi người” hoặc “cảnh báo dưới 3 giây” chỉ từ việc app mở được CSV. Ghi đúng phạm vi kiểm tra sẽ làm báo cáo dễ bảo vệ hơn.

Bài tự trình bày trong hai phút

Nói theo thứ tự: mục tiêu → dữ liệu/nhãn → lọc và đặc trưng → chia train/test → mô hình → kết quả thực có → phần còn thiếu. Dừng ở bằng chứng đã làm; nếu dùng ví dụ minh họa phải gọi đúng tên ví dụ.

20 Từ vựng và nguồn học tiếp

Từ	Cách hiểu trong tài liệu
Feature / label	Đặc trưng đầu vào / đáp án tham khảo
Sample / window	Một mẫu ML / khoảng tín hiệu tạo mẫu
Train / validation / test	Học tham số / chọn cấu hình / đánh giá cuối
Fit / predict	Học từ train / dự đoán bằng tham số đã học
Overfitting / leakage	Nhớ quá mức dữ liệu học / dùng thông tin đáng ra chưa được biết
LOSO / fold	Giữ một người ngoài tập học / một lượt đánh giá
Pipeline / scaler	Chuỗi xử lý / bộ chuẩn hóa theo train
FP / FN	Báo buồn ngủ nhầm / bỏ sót mẫu buồn ngủ
Offline / online	Xử lý sau khi đã có bản ghi / xử lý khi đang nhận dữ liệu

Tài liệu trực tuyến chính thức

S1 LeaveOneGroupOut

https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.LeaveOneGroupOut.html

S2 Common pitfalls

https://scikit-learn.org/stable/common_pitfalls.html

S3 Logistic Regression

https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression

S4 Confusion matrix

https://scikit-learn.org/stable/modules/generated/sklearn.metrics.confusion_matrix.html

V1 SEED VIG

https://bcmi.sjtu.edu.cn/home/seed/seed-vig.html

Nguồn nội bộ đã đối chiếu

N1: đề N16 trang PDF 10 và hướng dẫn NeuroSky. N2: driver OpenViBE 3.6.0 đã lưu đối chiếu cùng src/n16_eeg/ml_workbench.py, signal_features.py và sklearn_train.py. N3: output/processed_pilot/S01_batch_20261028_v1/batch_summary.json và các phiếu S01. N4: docs/SEED_VIG_DU_LIEU_THAT_20261028.md và inventory.json của dữ liệu thật.

Tài liệu này là giáo trình học theo trạng thái hồ sơ hiện có, không thay thế kết quả thực nghiệm hoặc quy trình được GVHD chốt. Khi mã hoặc quy tắc thay đổi, cần cập nhật phần mô tả tương ứng.